

SK 네트워크 Family AI 30기 : 5팀

수집 데이터 보고서

산출물 단계	데이터 수집 및 저장
제출 일자	2026. 08. 12.
깃허브 경로	https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN30-FINAL-5Team
작성 팀원	채동현

수집 데이터

1. 수집 데이터 개요

- LLM의 임의 추천을 제한할 운동 후보, 일반 성인 FITT·강도 근거와 안전·대체 규칙의 기반 데이터를 수집했다. 모든 결과는 DRAFT-AGENT_ONLY이며 운영 사용이 금지된다.

데이터명	수집 대상	수집 목적	사용 예정 기능	출처 / 저작권
국민체력100 동영상 정보	프레임 1,668행 영상 243개 운동명 후보 391개	국내 홈·생활도구 운동 후보 확보	운동 카탈로그·루틴 후보	공공데이터 API 메타데이터만 보존
wger 운동 카탈로그	운동 862개 번역 3,312개 헬스장 후보 400개	기구·프리웨이트 명칭과 장비 보강	카탈로그·대체 후보	wger 항목별 CC/CC0-저자 보존
신체활동 공식 근거	WHO-CDC-KDCA 원천 5종 Compendium 관련 활동 20건	FITT-MET-RPE 기준 확보	Training-Recovery 참고	공식 웹/PDF 원문 미재배포·출처 보존

2. 수집 방법 및 자동화 절차

2.1 수집 방식 (해당 항목에 체크)

수집 방식	선택	수집 방식	선택
웹 크롤링	☐	공개 API 호출	☒
사용자 입력	☐	공식 문서 파일(PDF/HTML)	☒
기타: 응답·구조화 사실 해시	☒	미디어 바이너리 수집	☐

2.2 자동화 및 예외 처리

사용 언어 / 라이브러리	Python 3.12, HTTP/API 클라이언트, json-csv-hashlib, pytest
자동화 여부 및 주기	시점별 승인 실행 후 불변 스냅샷 저장; 프로파일·시드·검증은 명령 기반 재현
오류 발생 시 예외 처리 전략	HTTP·필수 필드·해시·중복 검증 실패 시 부분 결과를 폐기하는 fail-closed 처리

2.3 예시 스크립트 또는 흐름도 첨부

공식 원천 확인 → API/문서 수집 → raw 불변 스냅샷 → 프로파일·후보 생성 → 검토 결정 → normalized 정책·참고 → generated 시드 → validation 시나리오

3. 데이터 설명 및 구성

3.1 파일 및 필드 설명

파일명 / 테이블명	필드명	데이터 타입	설명	예시
snapshot_manifest.json	retrieved_at	datetime	수집 시각(시간대 포함)	2026-08-11T18:00:00+09:00
exercises.jsonl	stable_code	string	서비스 내부 고유 운동 코드	standing_band_pulldown
exercises.jsonl	source_identity	string/int	원천 레코드 추적키	805
exercises.jsonl	equipment_codes	array[string]	정규화 장비 코드	[CABLE_MACHINE]
*_manifest.json	production_eligible	boolean	운영 사용 가능 여부	false

3.2 데이터 양

전체 수집 데이터 건수	KSPO 1,668행; wger 운동 862건; 공식 근거 사실 14건; Compendium 관련 활동 20건
추출된 고품질 데이터 건수 (필터링 후 기준)	검토 121건 중 운동 56건 포함; FITT 근거 10건; MET 관련 활동 20건

3.3 저장 위치 및 포맷

저장 경로	data/raw, data/normalized, data/generated, data/validation
저장 포맷	☒ JSON ☒ JSONL ☒ CSV ☒ Markdown/DOCX ☐ SQLite
인코딩	☒ UTF-8 ☐ 기타

4. 법적·윤리적 검토

개인정보 포함 여부	☐ 포함 ☒ 미포함
포함된 경우 필드	해당 없음. 사용자 건강기록·GPS·웨어러블 원시값·인증정보 미수집
비식별화 조치 여부	개인정보 미수집; API 키·토큰 저장 금지, 공개 기여자 귀속 메타데이터 분리
출처 및 사용권 — 공개 여부	☒ 공개 원천 ☐ 내부사용 한정
라이선스 / 약관 검토 여부	완료: 공공데이터 조건, wger 항목별 CC/CC0, 공식 문서별 사용 조건 기록
검토자	채동현 (에이전트 검증 보조)
검토 일자	2026. 08. 11. ~ 2026. 08. 12.

5. 데이터 품질 및 정합성 관리 방안

중복 제거 기준	원천 identity, stable_code, 한국어 표시명 중복 및 기능적 세부 변형 검토
정합성 검증 방법	SHA-256-바이트-레코드 수, 필수 필드, taxonomy, 허용 코드, 11개 골든 시나리오
Null 처리 및 결측치 전략	필수 의미가 없으면 제외; 원천 처방량·장비·운동명을 추정해 채우지 않음
표준화 전략	raw/normalized/generated 분리, UTF-8, 영문 stable code, 버전·검토·운영금지 상태 기록

6. 변경 이력 및 보완 내역

변경일	변경자	변경 내용	비고
2026.08.10	채동현	KSPO-wger 원천 스냅샷 수집·프로파일	원천/검증 계층 분리
2026.08.11	채동현	공식 FITT·강도·MET 근거 수집 및 121건 검토 완료	최종 운동 56건
2026.08.12	채동현	안전 354건·대체 238건·골든 11건 반영, 보고서 완성	운영 사용 금지 유지