

SK 네트워크스 Family AI 30기 : 5팀

데이터 전처리 결과서

산출물 단계	데이터 전처리
제출 일자	2026. 08. 12.
깃허브 경로	https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN30-FINAL-5Team
작성 팀원	채동현

데이터 전처리 프로세스 (Data Preprocessing)

1. 전처리 개요

- 전처리 목적: KSPO-wger 의 서로 다른 구조를 통합 가능한 운동 마스터로 정규화하고, FITT·강도 참고, 안전 규칙과 대체 관계를 분리해 멀티 에이전트가 재현 가능하게 조회하도록 한다.
- 전처리 범위: 원천 무결성 검증 → 후보 집계·프로파일 → 검토 결정 → 중복·불명확 후보 제거 → taxonomy·속성 정규화 → 안전·대체 파생 → 골든 검증
- 사용 도구: Python 3.12, JSON/CSV-SHA-256 처리, 프로젝트 검증 스크립트, pytest, ruff, mypy

2. 원천 데이터 분석

2.1 데이터 출처 및 품질 이슈

이슈 유형	대상 필드	판정 기준	처리 방식	처리량 / 비교
반복 프레임	KSPO 파일·운동명	동일 파일의 다중 프레임	파일+운동명 후보로 집계	1,668행 → 391후보
결측치	운동명	NULL / 빈 문자열	후보 생성 제외	15행
다중 의미	동영상 파일	한 파일에 여러 운동명	자동 병합 금지·개별 검토	49개 영상
번역·장비	wger name/equipment	한국어 없음·장비 근거 부족	별도 현지화, 추정 보완 금지	862건 / 장비근거 377
중복·변형	stable code·표시명	기능 중복·세부 변형	대표 후보만 INCLUDE	검토 121 / 제외 65
안전 추론	근육·설명·MET	자동 금기·강도 매핑	사용 금지, 검토 정책만 적용	fail-closed

2.2 품질 진단 결론

처리 단계	입력	출력	목적
원천 무결성	API·공식 문서	raw 스냅샷+SHA-256	출처·시점·권리 추적
후보 집계·프로파일	KSPO 프레임 / wger 리소스	후보 inventory·품질 통계	검토 단위 통일
검토·정규화	후보 121건	INCLUDE 56 / EXCLUDE 65	중복·불명확 후보 차단

처리 단계	입력	출력	목적
시드·파생 생성	정규화 속성·정책	카탈로그·안전·대체 관계	결정적 조회 데이터 생성
시나리오·재현 검증	생성 산출물	11 passed + 매니페스트	안전 veto·폴백·무결성 확인

KSPO 실행량 필드는 약 84~86%가 누락되어 원천 처방으로 사용할 수 없고, wger는 한국어 번역이 없어 명칭·안내를 별도 검토해야 한다. 불확실한 값을 채우지 않고 제외하는 원칙을 적용했다.

2.3 전처리 파이프라인 흐름

3. 정제·가공 결과 및 후속 활용

3.1 정규화 필드와 분할 정책

- 본 데이터는 ML/DL 학습용 표본이 아니므로 Train/Validation/Test 무작위 분할을 적용하지 않았다. 원천·정규화·생성·검증 계층과 버전 디렉터리로 데이터 누출과 덮어쓰기를 방지한다.

필드	타입	결측 처리	중복 처리	허용값 검증	비고
stable_code	STRING	필수 / 누락 실패	전체 고유	영문 machine code	DB 키 후보
name_ko	STRING	필수 / 별도 작성	표시명 고유	공백·금지표현 검사	키로 사용 안 함
training_type_code	ENUM	필수	-	STRENGTH/CARDIO/MOBILITY	taxonomy
body_area_codes	ARRAY[ENUM]	필수 부하 검토	중복 코드 제거	13개 허용 부위	안전 규칙 입력
equipment/location	ARRAY[ENUM]	추정 금지	중복 태그 제거	등록 taxonomy만	대체 필터 입력

3.2 결과·검증·재현성

구분	항목	기준 / 결과	설명 및 관리 방안
검토	후보 완전 분할	121건: 포함 56 / 제외 65 / 미결 0	결정·근거·역할별 증적 보존
카탈로그	운동 마스터	KSPO 26 / wger 30	기존 50 + 증분 6 분리
분포	유형·난이도	근력 50 / 유산소 2 / 모빌리티 4; 초급 37	부족 유형은 요구 발생 시 표적 수집
안전	제외·주의 규칙	354건: 패턴 96 / 운동 258	MILD/MODERATE 부위별 결정적 필터
대체	목표 보존 관계	238건; source 보유 운동 49개	난이도 상승 금지, 최종 안전 재검사

구분	항목	기준 / 결과	설명 및 관리 방안
골든	필수 시나리오	11 / 11 passed	원안 유지·안전 veto·변경·폴백
공중보건	FITT 근거	일반 성인 공식 근거 10건	개인 처방이 아닌 참고 envelope
강도	MET·RPE	Compendium 관련 활동 20건	운동별 자동 매핑 금지
품질	자동 검사	pytest 121 passed; ruff-mypy 통과	필수 필드·중복·해시·정책 검증
재현성	파생 재생성	3세트 8파일 byte-identical	입력·정책 버전과 SHA-256 고정
후속 활용	API·DB·사용자 노출	미적용	production_eligible=false, 운영 승격 별도

4. 변경 이력 및 적용 전략

변경일	변경자	변경 내용	영향 받는 항목	비고
2026.08.10	채동현	KSPO-wger 원천 수집·프로파일	raw / validation	v0.1
2026.08.11	채동현	110건 검토 및 50건 정규화	catalog / safety	MVP v0.2
2026.08.11	채동현	FITT·강도·MET 참고와 대체 관계 구축	normalized / generated	DRAFT
2026.08.11	채동현	tranche 3 6건 증분, 안전·대체·골든 확장	56 catalog / 354 / 238 / 11	AGENT_ONLY
2026.08.12	채동현	수집·전처리 최종 보고서 작성	reports	제출본